DOI：10.6328/CIEE.202206_(2).0011

管理 AI 的挑戰與工具介紹

宋經天、楊長恩、楊士逸、劉文山
財團法人資訊工業策進會 軟體技術研究院

企業導入 AI 現況

2012 年一篇運用深度學習的論文在國際比賽中異軍突起，接著 Google Brain 的 AI 圍棋打敗世界棋王。科技大廠紛紛投入開發更先進的 AI 演算法，同時也發現以機器學習技術產生的 AI 模型可以更精確、更廣泛的解決各種產業問題。在零售業，Aamzon 用 AI 打造了無人商店、銀行業用 AI 偵測信用卡盜刷、製造業用 AI 檢測產品瑕疵。一時之間，導入 AI 變成眾多企業進行數位轉型、提昇競爭力的重要策略 [1]。

導入 AI 遇到的問題

雖然許多企業有很高的意願投入 AI，但是往往遭遇幾個問題。首先是專業人才的缺乏，傳統的 IT 部門通常沒有資料分析的專長，更缺乏應用 AI 的能力，需要外部 AI 公司協助 [2]；其次是數據的準備不夠，現在的 AI 技術要靠大量數據去訓練 AI 模型，企業或者是數位化程度不足，沒有數據，或者是有了數據卻沒有分類整理，無法使用。企業好不容易克服前面的問題，完成一個 AI 驗證（PoC）計畫之後，想要大規模上線導入日常工作使用，卻發現還有一個系統整合的障礙橫擋在前。

相較於傳統 IT 系統只有程式碼的開發／整合／維運單一個維度的工作流程，一個 AI 系統的開發與維運，牽涉到：數據、模型、程式碼共三個維度的流程，複雜度與挑戰大增。因此，參考目前在程式開發維運被廣泛採用的整合式流程（Development + Operation, DevOPs），很多人開始倡議 AI 的整合開發流程（MLOPs），希望能透過標準化流程管理，簡化 AI 開發與運營的複雜度，減少不同部門重複投資，並加速企業導入 AI [3]。國外已有不少 AI 公司推出解決方案，國內也有新創公司投入這個領域 [4]。

誰需要管理 AI

隨著企業導入 AI 時間越久，數據會隨時間變化更動、AI 模型需要重新訓練產生、程式也會因功能與除錯而有不同版本，整個 AI 系統的版本組合會以 3 次方的速度成長，很快就會超出簡單人工可以處理的程度。所以第一類需要管理 AI 的企業，就是已經大量使用 AI 者。從規模來看，只要企業使用的 AI 模型數量、應用 AI 的計畫數、或參與 AI 的人數超過 10 個，都應該考慮導入 AI 管理的標準化作業流程。

第二類需要管理 AI 的企業則是來自法規與公司治理的需求。AI 對社會的影響深遠，

不可避免的要受到法規規範。歐盟已有法案將 AI 依風險高低分類規範，高風險 AI 應用將受到嚴格監管，違法最高可裁罰企業年營收 6%的罰款 [5]。企業因此需要將 AI 應用納入管理，確保合規。除了外在的法規要求，企業也有內部的社會責任目標，需要透過管理工具提供可被檢視的證據，確保企業在使用 AI 科技時是符合企業的社會責任。

如何導入 AI 管理

企業導入 AI 管理系統通常有外購與自建（Buy or Build）兩種方式。對於缺乏專業人才但是有充足經費的公司，採購現有的商業解決方案，是最快最容易的方式。但是企業如果有特殊需求，商業方案無法滿足，也可以考慮運用開源的軟體為基礎，自己開發自有的系統。無論採取哪個方式，對 AI 管理工具的認識都是很重要的。本文針對 AI 管理流程中的三種工具 : 資料前處理、模型自動化訓練、以及 AI 模型監測，以我們團隊在內部開發 AI 管理工具的經驗作簡介與分享。

一、高效資料前處理工具，加速資料處理節奏

數據資料前處理占據工程師於建構 AI 模型過程約八成的時間，一個好的資料處理決定後續訓練／預測模型的精準度的上限值，正因為如此導致大量工程師忙於領域知識的釐清與嘗試多種不同前處理的組合只為了為獲得關鍵且乾淨的資料。例如：建構一個製造工廠的品質或效率預測系統，此部分的前置作業則需要針對該工廠進行和品質與效率相關的資料進行彙整，較為常見的資料為：工單生產資料、品質驗測資料、機台保養紀錄、原料採購資料、機台 IOT 資料、訂單資料與委外生產資料等等，如圖一所示。如若將此案例變更為金融、餐飲、物流、電子或醫療業則所需的資料與預測目標也將則完全不同，然而，即使是相同產業在不同的應用情境與場域管理需求所延伸出的資料也會擁有大量相異的資料收集與紀錄的方式也有所差異，故此在數據資料的前處理時工程師需

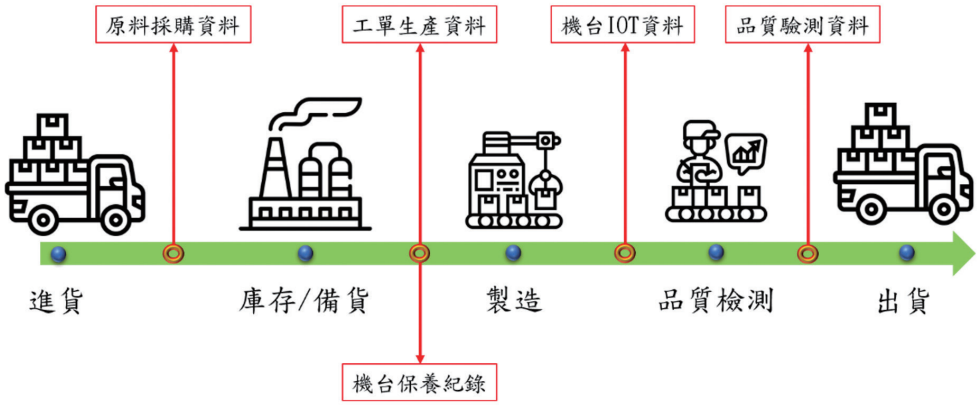

圖一　製造業生產流程示意圖

要適應不同的資料與了解不同的領域知識做最適當的資料前處理。

資料前處理的複雜程度與花費的時間成本決定於各行各業所提供的數據資料，所以數據的資料前處理可大略分為：資料清理、資料分析與資料特徵工程三大項目，如圖二所示，用於釐清各行各業的數據資料，同時過濾與調節資料因為 IOT 問題或人為紀錄因素導致資料產生缺值、誤植、亂碼、極端值或其他異常的樣態。我們以目前台灣製造業導入 AI 歷程中最為常見進行資料前處理是資料產生缺值、誤植、亂碼與極端值，此外則為同產業所收集的資料有著截然不同的樣態，故此資料工程師需要花費時間進行訪談與資料解析後才能選擇採用何種方式進行資料前處理。

基於上述，我們可獲知各產業對於 AI 模型的需求而延伸的多樣性的資料，對菜鳥工程師是一大挑戰。同時養成專業的資料工程師需要花費較多的時間成本，故擁有高效率資料前處理工具是當前需要解決的問題。目前市面上所提供的資料前處理工具大多採用 sklearn 前處理工具或提供基礎缺值補值的方法，又或是將其前處理部分規則融入 AuotML 工具（如：H2O 和 TPOP 等），但此部分的前處理僅能適應已經經過資料工程師使用過往經驗處理過後的資料，後續達到模型精確度的上限時仍然需要工程師重新解析資料，所以我們可以進一步總結高效資料前處理工具需具備簡易操作流程、資料分析、可視化資料、領域經驗傳承（紀錄工具使用的歷程與累積團隊開發經驗，並將各別產業於資料

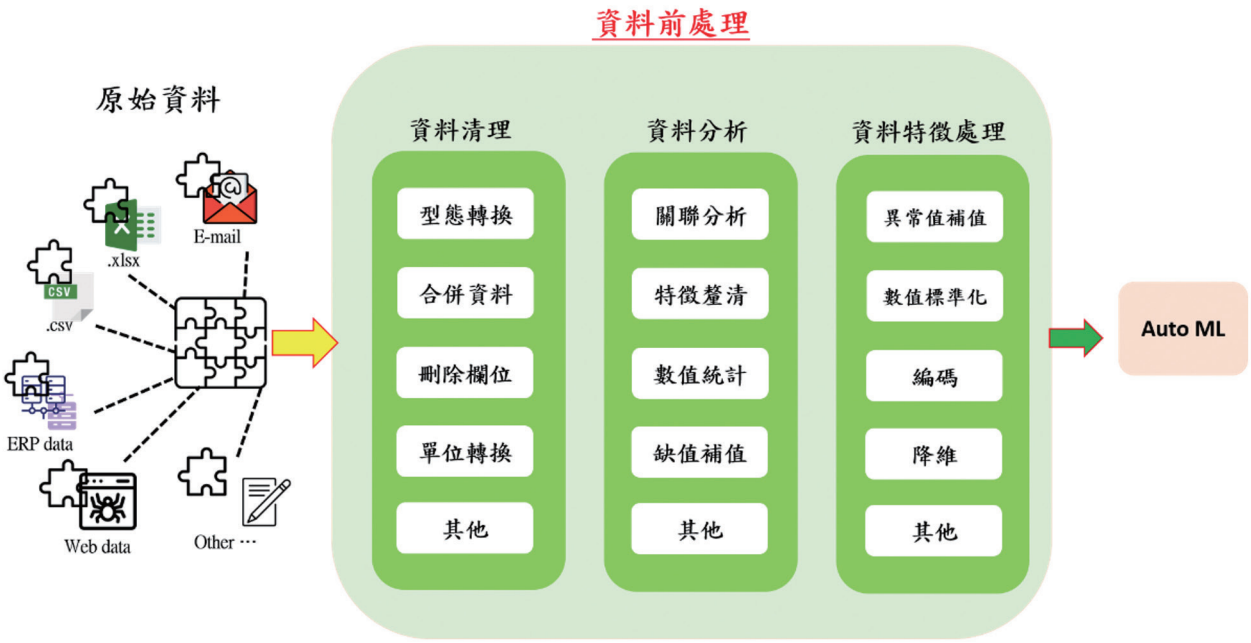

圖二　資料前處理示意圖

中較常發生的問題解法特徵進行紀錄，提供工程師未來於相同領域開發之參考或套用）與 low code 的資料處理模式，才可能從各產業的多樣性的資料中讓資料工程師提升效率，同時讓無資料處理經驗的工程師於短期學習後產出高品質的資料，同時加速資料處理節奏縮短整體 AI 模型開發的時程。

二、自動化機器學習模型訓練，沒有專業 AI 工程師也能迅速建出好模型

AI 模型的推論準確度，決定了實際應用於場域的成果，而為了提升準確度，不同領域應用所需要的 AI 模型，會基於不同演算法及超參數來建構。因此在訓練模型時，往往會遇到選擇演算法及超參數調教的議題，若是開發經驗或場域知識不足的開發人員，必須反覆地針對不同演算法及參數組合進行試誤（Try & Error）的過程，並持續調整及驗證模型，這是一個相當曠日廢時的任務，且常常經過大量的人、物力資源投入後，仍無法順利建構出好的模型，以符合場域的應用需求 [6]。

隨著企業導入 AI 的應用需求日益增加，上述議題的存在逐漸形成一個阻礙，自動化機器學習模型訓練（Automated Machine Learning - AutoML）的概念應運而生。這是一個結合 IT 的流程自動化及機器學習技術的整合性服務，AutoML 憑藉多樣的演算法，並藉由最佳化技術自動調整並尋找最佳的超參數，改變以往建構 AI 模型需要高度倚賴專業經驗工程師的生態，讓菜鳥工程師、甚至是毫無機器學習技術相關背景者，可在經過短期的學習後，建構出表現不輸專業 AI 從業人員的模型 [7]；此外 AutoML 提供的客製化訓練設定，也能使經驗老到的 AI 工程師，以更高效率且精準地尋找出最佳模型，進而加速企業導入 AI 的進程。

AutoML 所提供的一系列方法和自動化的學習流程，提高了應用機器學習的效率，亦加速了相關的研究與開發；依照支援演算法／超參數優化方式／訓練時間優化模式的不同，許多對應的開源工具亦如雨後春筍般冒出，底下列出目前熱門的開發者工具套件：

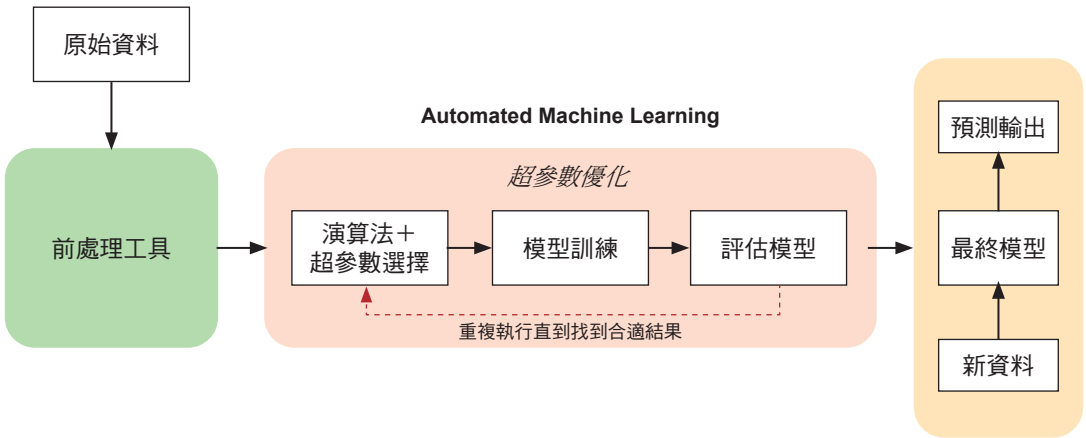

圖三　AutoML 於 MLOPs 流程中扮演之角色

圖四　著名 AutoML 套件 [8]

- AutoGluon
- FLAML
- H2O AutoML
- TPOT
- MLBox
- MLJar
- AutoKeras
- AutoSklearn

AutoML 透過集結專家的先驗知識，大幅降低了建構模型的難度。對於企業在評估特定 AI 應用之可行性與預期效益時，亦能扮演快速概念驗證（Proof of Concept）的角色；隨著近年來 No Code 無程式碼開發平台的一股潮流，訓練、建立、應用 AI 也不再是資訊背景的人才能做的事。因此，各大資訊企業亦紛紛搶佔這個商機，推出各自的 AutoML 平台，讓大家不用透過寫程式也能快速地進行資料探索與建立預測模型。以下列舉較著名的 AutoML 平台 [9]：

- Google: Cloud AutoML
- Microsoft: Azure Machine Learning
- Amazon: SageMaker Autopilot
- Landing AI: LandingLens
- Chimes AI: tukey

在現今 AI 的浪潮之下，AutoML 的出現成功縮短了專業與非專業人士，在建構 AI 的效率與品質上之差距。儘管它可能不適合用於尋找新的 AI 應用，但對於企業在評估特定 AI 應用之可行性與預期效益時，它亦能扮演快速概念驗證（Proof of Concept）的角色，是一個相當值得各家企業積極導入的方案。

三、自動化 AI 模型監測服務，讓上線的模型不會誤入歧途

訓練資料的數量與品質影響模型的效果甚巨。而隨著時間的演進，模型所要推論的新資料，可能已經和當初訓練的資料有很大

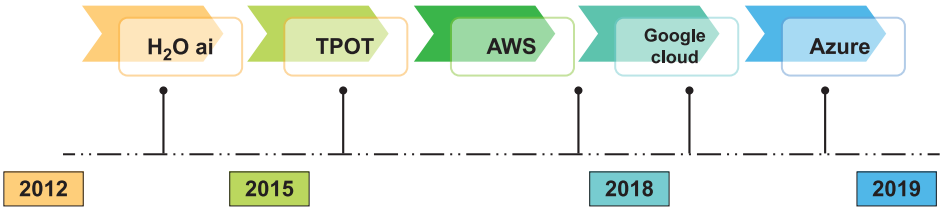

圖五　AutoML 平台發展 [10]

的不同，因此需要即時有效的掌握模型的運作情況。此外，當有很多個模型同時運作時，也要能快速掌握各個模型的狀態，這樣才能依據情況採取適當的調整策略。

為了能夠瞭解便需要有一套能監測模型狀態的工具平台。目前模型監測的工具平台中，較為常見的有 WhyLabs、Evdently、Seldon Deploy 與 Neptune 等等。這些工具在使用時，還是需要開發串接介面來蒐集模型表現的相關資料。而在不同應用情境中所要蒐集的模型資訊也不盡相同。針對模型監測的種類可以分成三個面向，分別是資料偏移、模型偏移與目標偏移。

1. 資料偏移

資料偏移主要是偵測特徵資料或資料品質是否發生變化。在這裡資料品質偵測是指原始資料中，缺失值或是異常值的分佈或比例是否與先前不同。而特徵資料偵測則是觀察資料的特徵分佈。當發現資料特徵分佈不同時，可能表示需要再重新調整模型。對於表格類型的數據（Tabular Data），可以比較相同特徵在不同時間範圍是否不同。而對於影像或是聲音等資料，可以偵測類神經網路的隱藏層、或是捲積層（Convolution Layer）的輸出的數值來做比較。比較的方法可以使用統計方法來檢定分佈的差異是否夠大，或是使用離群值偵測（Outliner Dtection）的方法 [11] 來找出可能是資料來源的問題。

2. 模型偏移

模型偏移是偵測模型評估指標的變化。常見用於迴歸問題的指標如均方誤差（Mean Squared Error, MSE）、絕對平均誤差（Mean Average Error, MAE），或決定係數 R^2（R-squared）等。而分類問題常用評估指標像是正確率（Accuracy）、精確律（Percision），或是召回率（Recall）等 [12]。這些指標通常會根

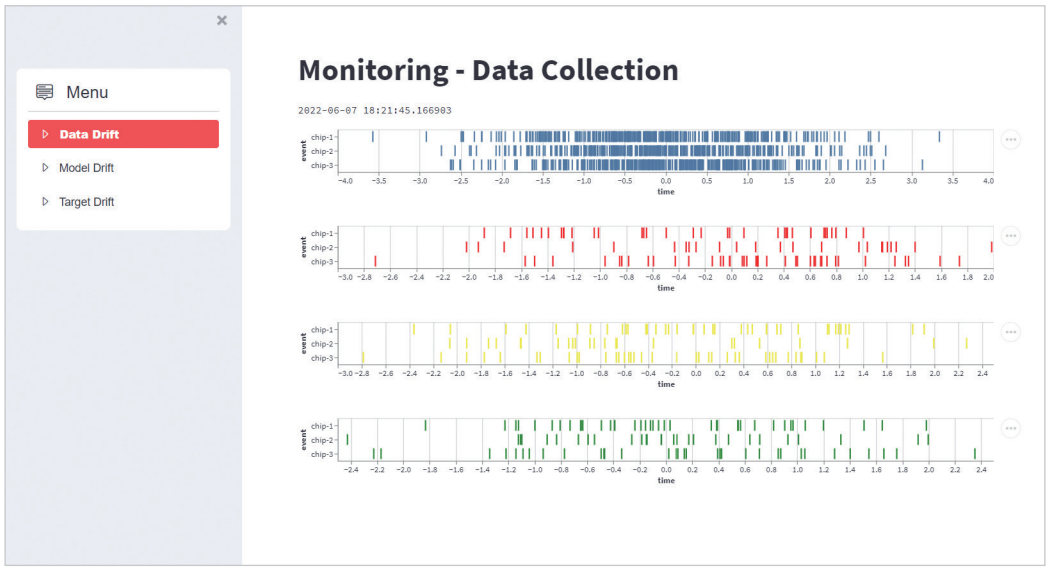

圖六　資料偏移偵測

據不同的應用情境來做選擇。如果因著新進資料而造成評估指標產生大幅的變動，就表明需要再重新審視資料，或是重新訓練模型。

除了觀察模型指標外，也能透過觀察樣本出現推論錯誤的時間與頻率來發現模型在哪些情況會有問題。從出現變化的時間點與頻率可以快速檢視有問題資料，找出何時開始出現新的類別，進而將新類別加入到訓練資料集中，加速建構出新的模型。而對於偵測是否有新樣本可以使用度量學習（metrics learning）方法來比較新舊樣本的差異程度 [13] [14]，進一步自動標記出未曾出現過的新類別樣本。

3. 目標偏移

目標偏移是指模型做完推論後結果的分佈情況是否發生變化。一般穩定情況，相同情境會有近似的結果。所以當發現推論結果分佈與過去比較差別很大，縱使模型評估指標與過去相近，也表示可能資料發生了變化，需要再重新檢視。

除此之外，記憶體、CPU 與 GPU 的運作情況也需要納入監測與紀錄的範圍，才能確保模型運作的環境可以正常地發揮作用。

四、結語

隨著 AI 應用的普及，AI 管理對企業日形重要。本文受限於經驗與篇幅，僅就三個與提升 AI 流程效率的自動化工具做簡介。AI 應用還有數據治理，模型解釋性、公平性等重要議題需要企業關注。拋磚引玉，盼望對加速產業導入有所幫助。■

【參考文獻】

[1] https://advisory.kpmg.us/articles/2021/thriving-in-an-ai-world.html

[2] Gartner: 77% Organizations Aim To Deploy AI, Staff Skill Holds Adoption Back https://www.rtinsights.com/gartner-ai-adoption/

[3] DIGITIMES Research 專欄：AI 產業聚焦優化開發方案　有助加速企業智慧化進程 https://www.digitimes.com.tw/tech/dt/n/shwnws.asp?cnlid=1&cat=240&cat1=35&id=0000599802_VD09KML1LOZPDT3HU8L9H&ct=y

[4] AI 應用高度客製化 InfuseAI 搶攻 MLOps 商機

[5] 歐盟委員會提出新人工智慧規範 https://iknow.stpi.narl.org.tw/Post/Read.aspx?PostID=17733

[6] https://www.digitimes.com.tw/iot/article.asp?cat=158&cat1=20&cat2=14&id=0000603801_Q0S9K0VJLRJ53124H9DW2

[7] https://www.automl.org/automl/

[8] https://medium.com/swlh/8-automl-libraries-to-automate-machine-learning-pipeline-3da0af08f636

[9] https://www.kdnuggets.com/2020/02/data-scientists-automl-replace.html

[10] https://www.analyticsvidhya.com/blog/2021/05/auto-ml-some-prominent-automl-libraries/

[11] https://scikit-learn.org/stable/modules/outlier_detection.html

[12] https://medium.com/analytics-vidhya/different-metrics-to-evaluate-the-performance-of-a-machine-learning-model-90acec9e8726

[13] http://contrib.scikit-learn.org/metric-learn/introduction.html

[14] Kaya, Mahmut, and Hasan Sakir Bilge. “Deep metric learning: A survey,” Symmetry 11.9 (2019): 1066